ChatGPT

面向全民与个性化的人工智能素养测评研究：F0701适配性、国内外进展与自然科学基金申报设计报告

执行摘要

结论先行：F0701“教育信息科学与技术”与拟议研究方向高度适配，建议作为国家自然科学基金申请时优先考虑的申请代码。 2026年度国家自然科学基金信息科学部申请代码中，F07为“交叉学科中的信息科学”，F0701为“教育信息科学与技术”；当前指南页面呈现到F0701层级，并未继续呈现早期的F070101—F070110细分代码。历史上，F0701的细分领域曾明确包含“学习分析与评测”和“自适应个性化辅助学习”，与“人工智能素养测评—智能诊断—个性化指导”的研究链条具有直接学术渊源。申报2027年度项目时，应以届时正式指南为最终依据，切勿继续填写历史三级代码。 [1]

从近年F0701项目和年度会议看，人工智能、教育大模型、智能评价、自适应学习已经进入该方向核心议题。华东师范大学江波团队连续承担“面向图形化编程项目式学习的自动评价研究及应用”“中小学信息科技核心素养自动评价研究”“对话式导学中面向知识建构的有效对话生成机制研究”等国家自然科学基金和上海市自然科学基金项目；2024年F0701年度会议主题直接采用“数智新教育—AI for Education Science”。北京大学尚俊杰2024—2027年承担F0701面上项目“基于视频游戏的空间能力测评关键技术及工具开发研究”。这些案例共同说明，**“教育构念 + 测量理论 + 计算模型 + 智能系统验证”是F0701中已经形成清晰研究谱系的路线。** [2]

本课题最值得申报的定位并非泛化地“建设一个全民AI素养测评平台”，更有竞争力的表述是：

> **研究人工智能快速演化条件下，多群体AI素养潜在能力结构的形成、跨群体等值与动态漂移规律；研究如何从人—AI真实交互过程证据中估计潜在能力状态，并通过心理测量约束的大模型评分与自适应测验实现可信诊断；进一步验证基于诊断结果的个性化指导如何促进能力迁移。**

这样能够把工程目标转化为三个自然科学问题：**构念如何测得准、动态能力如何估得稳、诊断如何真正促进学习。** 这更符合自然科学基金官方评审中反复强调的关键科学问题、原创性、方案科学性和可行性导向。 [3]

国际测评正在出现一个十分重要的范式转移。UNESCO 2024学生AI能力框架提出“以人为本、AI伦理、AI技术与应用、AI系统设计”四个方面以及Understand—Apply—Create三级进阶；OECD与欧盟委员会2026年正式发布中小学AI素养框架，将AI素养组织为Engage、Create、Manage、Shape四类实践，同时以知识、技能、态度描述学习结果；OECD PISA 2029已经确定“媒体与人工智能素养（MAIL）”为创新测评领域，并计划采用传统题目与模拟互联网、社交媒体和AI工具环境相结合的方式。由此可以判断，未来高水平AI素养测评很难长期停留在Likert自陈量表层面，更可能转向**情境化任务、真实人机协同、过程日志、开放作答和动态诊断。** [4]

国内目前仍以“指标体系 + 问卷量表”为主。武汉大学AILES-CS采用“态度—知识—能力—伦理”四维结构、10个二级指标和25个三级指标，通过两轮Delphi、AHP赋权、31项Likert量表和1,651名本科生进行实证验证；2025年的大学生生成式AI素养测评进一步形成GenAI-AKSTE模型，覆盖意识、知识、技能、伦理等结构。但AILES-CS论文自己已经指出其主要采用静态评价，后续需要进入情境化和动态评价。2026年的一项中文系统回顾已纳入69项AI素养测评研究，也显示这一领域正在从“定义素养”快速转向“如何有效测量素养”。 [5]

因此，本报告建议把课题的核心创新集中为：

“共尺度构念模型 + 混合任务题库 + 过程证据建模 + 心理测量约束的大模型评分 + 认知诊断自适应测验 + 因果验证的个性化指导”六位一体框架。

其中大模型承担开放题评分、动态任务生成、误概念解释和反馈语言生成等角色；**最终能力值不建议直接采用LLM一句话评分，而应由IRT/MIRT、认知诊断模型、评分置信度、专家标注和过程证据共同约束。** ETS关于AI评分的研究明确强调，可信自动评分需要证明系统“因为有效理由而给出正确分数”，并关注解释性、公平性和偏差；最新LLM自动评分研究同样表明，评分一致性、prompt敏感性、跨模型稳定性和群体差异均需单独验证。 6

对“全民”这一目标，本报告建议采用**“共同核心量尺 + 人群模块”**，而不追求所有人做同一套试卷。共同核心用于连接中小学生、大学生、教师、职场成人等群体；具体模块根据年龄、角色和应用情境进行适配。这样既能形成全民可比的公共量尺，又可以避免用中小学AI编程知识测试老年人、或者用大学生prompt工程题衡量儿童AI伦理理解等明显的构念污染。UNESCO框架本身强调年龄适宜性和能力进阶，OECD 2026框架也通过学习者期望和发展性描述组织能力，而非设定一个固定年级的一刀切标准。 7

需要特别提醒申请资格。 用户本人身份描述为“博士”，但“是否全日制在读博士、是否在职攻读、是否具有人事关系”均为**未指定**。国家自然科学基金面上项目现行官方规定明确：正在攻读研究生学位者不得作为面上项目申请人；在职攻读研究生学位者，经导师同意，可通过受聘依托单位申请。上海市2025年度自然科学基金则要求项目负责人依托其**人事关系所在单位**申报。因此，如本人为普通全日制博士研究生，本项目更现实的组织模式是由符合资格的导师或课题组教师担任PI，本人作为核心研究骨干承担构念设计、实验、算法和论文工作。 8

本报告若干前提目前为**未指定**：申请年度未指定，本报告以截至2026年9月1日可核实的2026年NSFC规则为基础并面向下一轮申报提出建议；上海项目类型未指定；受测“全民”的最低/最高年龄未指定；合作学校、成人样本渠道未指定；课题组已有GPU、服务器及大模型API资源未指定；PI职称、人事关系和在研项目情况未指定。因此，以下样本规模、预算及技术资源均按“可申报版本”进行粗略设计，而非最终申报数值。

基金适配性与评审偏好

F0701为什么适配

2026年度NSFC申请代码将F0701列为“教育信息科学与技术”。F0701自2018年前后形成独立资助方向，其设立目的之一就是推动教育研究与信息科学、自然科学研究范式深度结合。历史版本中曾设“学习分析与评测”“自适应个性化辅助学习”等细分方向，虽然这些三级代码今天已经不能直接作为当前申报代码使用，但它们十分清楚地揭示了F0701长期资助的问题域。 9

从已公开项目看，测评本身完全可以成为F0701的核心研究对象。北京大学尚俊杰承担的62377001号项目明确以“视频游戏的空间能力测评关键技术及工具开发”为核心；华东师范大学江波先后研究编程项目自动评价、中小学信息科技核心素养自动评价以及对话式导学的知识建构机制。这说明“能力构念—数字任务—自动评价算法—学习反馈”可以自然进入F0701，只要研究真正提出可解释、可验证的科学问题。 10

华中师范大学孙建文当前主持“中国自动化学会教科研重大项目‘数智驱动的青少年人工智能素养测评’”，同时承担国家自然科学基金重大项目子课题“交互行为增强的可归因教学诊断”和国家重点研发计划子课题“服务专业素养发展的终身学习评价生成方法及系统构建”。这一组合尤其值得借鉴：**素养测评可以与行为建模、认知诊断、评价生成、教育大模型形成一个连续的科学研究链条。** 11

因此，本报告对申请代码的建议为：

研究主轴	F0701适配判断	申报策略
AI素养构念、数字化测评、学习分析、智能诊断、自适应反馈	**高**	建议F0701作为第一申请代码
LLM自动评分，但核心问题是教育测量的效度、信度、公平性	**高**	保留F0701，以“可信智能测评”组织算法
通用LLM训练算法、模型压缩、推理加速，教育仅是测试场景	中—低	应重新核对当年人工智能相关代码
“开发一个AI素养平台/APP”	低	平台作为验证载体，重写为科学问题
AI素养指标体系 + 问卷调查	中	单独作为自科主线创新度不足，应升级到动态、客观和过程测量
多人群共尺度 + 人机交互任务 + 认知诊断 + 个性化干预	**很高**	最有机会形成F0701特色

自科评审真正关心什么

国家自然科学基金官方近年的项目评审会议表述中，反复出现“关键科学问题”“原创性”“科学目标”“研究内容的科学性”“技术方案可行性”“前瞻性”等标准；从2024年起，多类项目还按照“自由探索类基础研究”和“目标导向类基础研究”进行分类评审。拟议AI素养项目直接回应人工智能时代公共能力发展需求，因此在目前政策逻辑下，**“目标导向类基础研究”具有较强叙事一致性，但最终应根据申请年度指南及PI具体科学问题选择。** [12]

上海市自然科学基金管理办法同样把基础研究和应用基础研究作为核心，强调科学前沿、重要应用需求和战略意义，尤其关注学术思想的新颖性、理论基础、目标明确性、研究方法先进合理且可行，以及团队基础和条件；评审涉及科学价值、创新性、社会影响和可行性。2025年度指南进一步明确支持科研人员面向科技前沿和重大应用需求凝练**关键科学问题**、开展原创和交叉研究。 [13]

由此，对本课题来说，最危险的写法是：

> “开发基于大模型的全民人工智能素养测评与指导平台，建设题库，自动评分，并实现个性化推荐。”

这是一组工程任务，评审人很容易继续追问：**哪个基础规律目前不知道？算法困难究竟在哪里？为什么已有IRT、CAT、LLM、推荐系统不能直接解决？**

更适合自科申请书的科学问题可以凝练为三个层次：

构念层。 AI工具持续迭代、不同人群任务需求显著异质时，AI素养究竟是否存在稳定的共同潜变量结构？哪些能力属于跨人群公共核心，哪些属于角色特异能力？技术变化引起的分数变化如何与真实能力增长区分？

测量层。 在“允许使用AI完成任务”的测评条件下，传统最终答案分数难以区分学习者原有能力、提示策略、人机协同能力和模型本身能力。如何利用prompt序列、修订行为、验证操作、AI输出采纳/拒绝、耗时和最终产物等过程证据，识别人的潜在AI素养？

反馈层。 精细诊断能否可靠地转化为下一步学习建议？什么粒度的反馈能够改善AI素养和远迁移，什么反馈只会短期提高下一道题的成绩？这一问题可由随机对照实验建立“测—诊—导”的因果闭环。OECD对复杂技能与数字学习测评的研究已经将实验、信息搜索、显式反馈和过程数据作为新型测评的重要证据来源。 14

对课题组结构的一个重要判断

教育技术学学生作为主要研究人员，与F0701的教育信息科学定位具有天然契合性；但若现有成员主要来自教育技术学，**心理测量/教育测量与LLM算法两端可能成为评审中的能力短板**。江波团队公开研究轨迹同时覆盖数据挖掘、知识追踪、学习分析、编程教育、自适应学习和教育大模型，正体现了F0701对技术与教育实质融合的要求。 15

建议形成“教育测量—教育技术—人工智能—统计方法”四类能力组合。其中至少应有一位成员能够独立处理IRT/CDM/CAT及测量不变性问题，一位能够处理LLM推理/微调/RAG与服务部署，一位负责构念、课程与学习理论，一位负责平台和数据工程。**合作方式和具体合作专家：未指定。**

上海基金与国自然需要区分体量

截至本次检索，上海市科委官网能够明确核实到的最近一版常规年度“自然科学基金”指南为2025年度：面上项目定额20万元、青年项目定额25万元，执行期均为三年，并采用两轮通讯评审；2026年官网另有“探索者计划”等基础研究计划公开指南，因此下一轮常规自然科学基金的资助额度和限制条件应等待最新正式通知，不能把2025规则直接外推。 16

国家自然科学基金面上项目官方页面显示，2025年度约资助2.3万项、直接费用约114亿元，平均直接费用资助强度约50万元/项。这可以作为内部设计科研体量时的参考基线，下一年度实际预算仍应依据正式指南与研究需要编制。 17

因此更合理的两级策略是：

上海自然科学基金： 聚焦“AI素养自动测量/过程证据建模”中的一个关键科学问题，建立上海样本、多类型题库、原型系统和核心算法。

NSFC面上项目： 扩展到跨群体共尺度、动态测量、认知诊断、LLM可信评分和个性化干预机制，形成较完整的理论—算法—实验链。

国内外研究与项目版图

下面的比较表优先纳入高校、国际组织、科研机构官网以及正式期刊论文。对于仅能从项目主页确认题目、尚未公开具体题库或算法的项目，表中明确标记“公开资料未披露”，避免根据项目名称反推技术细节。

项目/论文	作者/机构	年份	测评维度/对象	方法与题型	可借鉴点	链接
中小学信息科技核心素养自动评价研究	江波；华东师范大学	2023–2026	中小学信息科技核心素养	上海市自然科学基金；公开主页未披露完整题库、评分模型	**与你们拟报上海自科最接近的直接先例**；“核心素养+自动评价”可进入自然科学基金	18

项目/论文	作者/机构	年份	测评维度/对象	方法与题型	可借鉴点	链接
面向图形化编程项目式学习的自动评价研究及应用	江波；华东师范大学	2020–2023	编程、项目式学习、计算思维相关表现	NSFC面上；结合其团队论文可见编程轨迹分析、Scratch与计算思维研究积累	从最终答案扩展到**学习作品与编程轨迹证据**	15
对话式导学中面向知识建构的有效对话生成机制研究	江波；华东师范大学	2025–2028	对话学习、知识建构	NSFC面上；LLM/对话智能相关机制研究	可借鉴为“LLM反馈为何有效”的机制研究范式	15
数智驱动的青少年人工智能素养测评	孙建文；华中师范大学	2025–2026	青少年AI素养	中国自动化学会教科研重大项目；具体测量工具尚未从项目主页完整公开	国内与你们选题名称最接近的项目，应持续跟踪论文与成果	11
基于视频游戏的空间能力测评关键技术及工具开发研究	尚俊杰；北京大学	2024–2027	空间能力	NSFC F0701面上，游戏化测评	直接证明**能力测评关键技术+工具开发**可在F0701成立	19
AILES-CS大学生AI素养评价体系	吴丹等；武汉大学/港大	2025	态度、知识、能力、伦理；10个二级、25个三级指标	Delphi两轮、AHP赋权、31项5点Likert；预测试139人，正式样本1,651人	国内成熟的指标开发流程；适合作为构念初始框架和效度研究对照组	20
大学生生成式人工智能素养测评工具	刘明、郭烁、苏逸飞等	2025	GenAI意识、知识、技能发展、伦理认知等AKSTE结构	量表开发、多阶因子验证；39个保留题项的公开文本可见	将一般AI素养推进到GenAI操作、问题建构、认知交互、迭代反思等能力	21
中小学生人工智能课程指南	华东师范大学、上海人工智能实验室，江波等	2023	AI课程核心素养、课程目标、学习内容、学业质量	课程指南与学业质量评价标准	适合建立**“学习目标—任务—评价证据”对齐关系**	22
中小学生信息素养评价指标体系	吴砥等；北京师范大学相关团队	2016起多轮应用	信息意识与认知、信息科学知识、信息应用与创新、信息道德与法律	文献+专家咨询；测试题+问卷；在线大规模评测；跨地区样本；信效度分析	国内“素养—大规模数字化测评”重要前身；可借鉴区域抽样和系统化实施	23

项目/论文	作者/机构	年份	测评维度/对象	方法与题型	可借鉴点	链接
What is AI Literacy?	Long & Magerko；Georgia Tech	2020	批判评价AI、与AI沟通协作、使用AI等AI literacy competencies	跨学科文献综合形成能力框架	国际AI素养研究的基础概念来源；适合用于构念内容效度	24
UNESCO AI Competency Framework for Students	UNESCO	2024	以人为本、AI伦理、技术与应用、系统设计	12个能力块；Understand–Apply–Create三级进阶	最适合作为**年龄发展与能力进阶**理论来源之一	25
Empowering Learners for the Age of AI	OECD/ European Commission	2026	Engage、Create、Manage、Shape；知识、技能、态度	面向中小学AI素养的发展性框架	最新国际政策框架；特别强化人类主体性、人机分工和“塑造AI”	26
PISA 2029 Media & AI Literacy	OECD	2029规划	媒体与AI理解、批判评价、伦理社会影响、人机互动等	传统题目 + 模拟互联网/社交媒体/AI工具环境	**全民/大规模AI素养数字测评最重要的未来国际标杆之一**	27
GLAT: Generative AI Literacy Assessment Test	Jin、Martinez-Maldonado、Gašević、Yan；Monash	2025	GenAI核心能力	20题客观测试；结合经典测验理论与IRT；验证与GenAI支持任务表现的关系	从“自我感觉会不会AI”转向**客观能力测试**；适合作为效标工具	28
AICOS: AI Competency Objective Scale	Markus、Carolus、Wienrich	2025	一般AI素养+GenAI能力	知识型客观题；多维、模块化设计及短版	进一步证明国际研究正在从self-report向objective measurement演进	29
Bebras Computational Thinking Challenge	国际Bebras组织	持续项目	抽象、算法、信息、逻辑等计算思维	情境化短任务；大规模挑战赛	题目看似简单生活情境，实际映射计算概念，适合作为全民AI素养情境题设计先例	30

项目/论文	作者/机构	年份	测评维度/对象	方法与题型	可借鉴点	链接
Dr. Scratch	自动化Scratch项目分析工具	持续项目	Scratch作品中的计算概念/计算思维	自动静态分析作品；rubric评分；推荐改进	**“作品—自动诊断—反馈”闭环**值得AI创作任务直接借鉴	31
ICILS 2023/2028	IEA	2023/2028	计算机与信息素养、计算思维	国际大规模数字化测评，含任务、问卷及过程数据	抽样、量尺等值、数字任务、安全题库和过程数据管理经验	32
AI辅助自动评分研究	ETS及ACL/BEA相关研究	2024–2026	作文、短答、开放反应	LLM rubric评分、人与AI一致性、解释性、公平性、置信度	LLM可用作评分器，但必须接受效度、公平、稳定性和人工复核约束	33

从这些工作中可以看到的研究空档

第一，**指标体系已经相当丰富，客观和过程性测量仍显不足。** 武汉大学AILES-CS已经形成完整的指标—专家—赋权—量表—实证流程，但作者明确指出当前工具主要是静态评价，未来需要情境化设计和实验方法。国际上AICOS和GLAT则直接把重点放到objective measurement上。 34

第二，**AI素养尤其需要区分“无AI能力”和“与AI共同完成任务的能力”。** OECD 2026框架中的Manage AI明确强调人在AI时代需要有意识地分配人和AI各自承担的工作；Create、Engage、Shape进一步涉及创造、判断和改变AI系统。这意味着“允许使用AI的测评”应成为AI素养测评的组成部分，而非简单认定为作弊。 26

第三，**高水平智能评价开始关注过程，而非只看最终答案。** PISA数字化测评已经使用适应性测验，并研究如何利用事件日志等过程数据解释能力、参与度与自我调节；PISA 2029 MAIL进一步计划使用真实感AI环境。这与江波团队关于编程轨迹、数字教材回溯行为和知识状态预测的研究路径高度一致。 35

第四，**大模型评分能够降低开放任务的规模化成本，却同时产生新的测量误差。** ETS强调模型应在正确理由上得到正确分数；ACL近年的工作持续研究rubric、提示方式、模型尺寸、重复评分一致性以及人工分歧。因而“LLM评分准不准”本身还不够，真正有价值的科学问题是**如何把LLM的不确定性嵌入心理测量模型并形成可校准、可拒答、可人工接管的评分机制。** 36

典型测评体系的技术剖析

建议采用怎样的AI素养构念

综合Long & Magerko、UNESCO、OECD 2026、武汉大学AILES-CS以及国内GenAI-AKSTE研究，本报告建议建立一个**“五域 × 三级发展 × 多人群模块”**模型。这个结构属于本报告提出的研究假设，需要通过专家研究、认知访谈、因子模型、IRT/CDM以及跨群组验证最终确定。理论来源分别强调批判评价与人机协作、以人为本和伦理、AI技术与系统设计、Engage/Create/Manage/Shape以及态度—知识—能力—伦理。 37

建议一级维度	关键能力	典型可观察证据
AI原理与认知	识别AI、理解数据/模型/生成机制、理解局限	概念题、模型选择题、错误原因解释
AI使用与交互	任务分解、prompt构建、多轮交互、工具选择	prompt轨迹、工具调用、修改策略
AI批判评价	事实核查、幻觉识别、来源判断、偏差判断	是否核验、采用/拒绝AI建议及其理由
人机协同与创造	合理分工、整合AI结果、创造产品、优化系统	过程日志、作品、任务表现、反思说明
AI伦理与主体性	隐私、版权、公平、安全、人类责任、过度依赖	情境判断题、伦理决策、隐私行为证据

纵向发展可以先采用“**理解—应用—创造/反思**”三个阶段，并与UNESCO的Understand—Apply—Create保持可解释映射；后续通过数据验证是否需要将“批判反思”独立为更高层级。 38

对不同人群，不建议另外创造完全不同的AI素养定义，而建议采用：

$$\text{个人AI素养} = \text{共同核心能力} + \text{人群/角色模块} + \text{情境表现}$$

其中共同核心负责量尺连接；儿童模块强调识别、安全、简单人机互动；大学生增加学术任务、生成式AI、知识验证；教师增加AI教学、评价和专业责任；职场成人增加任务代理、人机分工、决策与数据风险。教师框架本身也显示，教师AI能力还应包含AI教学法和专业学习，因此教师不能简单使用学生版测验。 39

题库最好从“题目集合”升级为“证据任务库”

建议至少建立五类题。

锚定客观题。 单选、多选、排序、匹配和短情境题，用于建立稳定的共同量尺。GLAT和AICOS表明客观能力测试是克服AI素养自陈偏差的重要方向。 40

情境判断题。 给出“老师要求使用AI完成作业”“AI生成疑似虚假健康信息”“上传含个人信息的数据给模型”等情境，要求作出选择并说明原因。伦理和批判判断特别适合这一题型，UNESCO明确将安全负责使用、伦理设计、隐私、公平和人类责任纳入AI能力。 41

模拟人—AI交互任务。 在受控LLM环境中让受测者完成“查证新闻”“写研究摘要”“修改代码”“比较AI建议”等任务；记录所有prompt、模型回复、重写、复制、引用、搜索、核验和最终提交。PISA 2029 MAIL计划采用模拟互联网、社交媒体和AI环境，这为该模式提供了直接国际先例。 42

开放解释题。 例如“请解释为什么这个AI答案不可靠”“为解决该问题设计与AI协作的步骤”。这一类最适合测试高阶判断，但大规模评分需要rubric与LLM结合。已有研究显示LLM能够进行开放回答/作文自动评分，但必须针对人与模型一致性、评分理由、重复稳定性和公平性进行验证。 43

作品任务。 让学习者产生prompt方案、AI辅助代码、图像/文本产品或者决策报告，再从“过程+成品”共同评价。Dr. Scratch对程序作品自动分析、江波团队的编程轨迹分析均提供了成熟的教育测评类比。 44

建议初始题库达到约**400—600个可校准任务/题项**；其中具体比例属于**未指定、需预测试验证**。与其大量生成同质选择题，更值得投入资源建设约50—100个高质量交互/开放任务，因为它们能够产生目前AI素养研究最缺乏的真实性过程证据。

评分机制：让心理测量模型控制LLM

建议采用四层评分架构。

第一层是**规则评分**，处理标准答案、工具操作、事实核验步骤等高度确定项目。

第二层是**心理测量评分**。客观题可以使用多维IRT建立公共能力量尺；需要诊断具体技能掌握状态时使用认知诊断模型。CD-CAT已经被用于把认知诊断的细粒度反馈与计算机自适应测验的效率结合起来，近年的研究继续改进项目选择与暴露控制。 45

第三层是**LLM rubric评分**。模型根据细粒度评分规程输出各维度得分、证据片段及置信度；不要让模型只输出一个0—100总分。ETS及近期研究强调解释性、rubric设计和构念相关评分特征的重要性。 46

第四层是**人机仲裁**。对低置信、模型间分歧、与IRT预测严重不一致、敏感群体异常DIF或者高风险伦理判断，自动转给人工。这样形成：

$$P(\theta \mid X) \propto P(X_{\text{objective}}, X_{\text{process}}, X_{\text{LLM}}, X_{\text{human}} \mid \theta) P(\theta)$$

其中 θ 表示潜在AI素养及其子能力。**这类“心理测量约束的LLM评分”本身就有潜力成为一个F0701算法创新点。**

数据采集与标注

传统测评保留“答案正确/错误、分数、作答时间”等数据；交互任务则建议进一步采集事件级日志：打开任务、输入prompt、修改prompt、模型回复、引用信息、外部核验、删除/采纳AI结果、重新生成、最终提交。OECD关于数字测评和过程数据的工作表明，数字环境能够把行为过程转换成测量证据，并用于研究自我调节、参与状态和能力表现。 14

标注流程建议采取“**专家双标—冲突仲裁—LLM预标—主动学习抽检**”。第一批金标准由至少两名专家独立评分并进行评分者一致性检验；模型只能学习或辅助扩展这一标准，不能自己生成标签后再用自己的标签证明自己有效。对于模型不确定度最高、人—机分歧最大的样本优先投入专家标注资源，可显著提高标注效率。这属于本报告的算法设计建议。

还应把“评分标签”与“误概念标签”分开。例如，一个受测者识别出AI回答错误，但理由是“AI永远都不能信”，其最终判断可以得分，认知解释仍暴露另一个误概念。这样的标签体系更适合后续个性化指导。

个性化反馈不能止步于“雷达图”

传统系统往往输出“你的AI知识82分、伦理76分”。认知诊断模型的价值在于识别更具体的能力组合，而CAT与认知诊断结合的研究本来就以提供细粒度学习反馈为目标。 47

建议输出四层反馈：

> **能力状态 → 证据 → 原因/误概念 → 下一步学习行动**

例如：

> “你在‘AI输出验证’维度处于L2，可信区间较宽。三项任务中，你两次直接采纳AI生成的数据而没有寻找外部来源；你能够识别明显错误，但对看似专业的错误内容缺乏交叉验证。建议完成‘多源核验’微学习任务，并在下一次测验中进入信息来源判断模块。”

LLM最适合承担最后一层的自然语言解释和案例生成；“能力状态”仍由测量模型给出，“证据”必须来自真实作答过程。这样可以减少模型编造学习者缺陷的风险。

更重要的是，**反馈有效性必须通过实验检验。** 可以随机分为“仅分数报告”“一般建议”“诊断证据+个性化指导”三组，比较即时后测、延迟后测以及迁移任务表现。这样，“个性化指导”从产品功能上升为可发表、可申报的因果机制研究。

伦理、隐私与合规

这一课题几乎必然属于应开展科技伦理审查的研究。科技部《科技伦理审查办法（试行）》第二条明确涵盖以人为测试、调查、观察对象，以及利用个人信息数据开展的科技活动；上海市2025自然科学基金指南进一步要求所有拟开展科技活动进行科技伦理风险评估，属于该办法第二条范围的项目应提交相应伦理审查批准材料。[48]

如涉及中小学生，要求进一步提高。个人信息保护法将不满14周岁未成年人的个人信息作为敏感个人信息予以特殊保护；相关规定要求处理此类信息取得父母或其他监护人同意，并制定专门处理规则。[49]

建议在系统层面执行：数据最小化、研究ID与身份信息分库、敏感字段加密、访问权限控制、日志留痕、研究数据与模型训练数据隔离、可删除/撤回机制。尤其不要默认把学生prompt和作品发送到未经科研协议约束的第三方公共LLM，因为输入中可能包含姓名、学校、作业、隐私或知识产权内容；国家网信办对生成式AI治理的政策解读也明确提醒，用户输入数据可能进入后续模型训练或输出，形成泄露风险。[50]

个人信息保护法还要求自动化决策具备透明、公平、公正要求；对个人权益具有重大影响的自动化决定，个人具有请求说明等权利。因此，如果系统未来用于正式评价、分层、认证或教育资源推荐，必须保留人工复核、解释和申诉路径。[51]

《生成式人工智能服务管理暂行办法》适用于向境内公众提供生成式AI服务；教育科研机构内部研发应用且未向境内公众提供服务的情形，监管适用范围不同。若最终系统开放成为“全民公共测评服务”，就需要重新核对服务备案、安全、生成内容治理等要求。自2025年9月1日起实施的AI生成合成内容标识制度还要求相关适用服务对生成合成内容进行显式/隐式标识，因此将来公开发布LLM生成的个性化指导时也应在产品阶段同步核查。[52]

建议的总体研究设计与技术路线

教育学应当位于模型最底层

本研究最需要避免“大模型找教育场景”。更稳健的逻辑是：

$$\text{学习目标} \rightarrow \text{能力构念} \rightarrow \text{可观察证据} \rightarrow \text{测评任务} \rightarrow \text{测量模型} \rightarrow \text{学习诊断} \rightarrow \text{教学干预}$$

在**学习目标层**，可以使用UNESCO的能力进阶以及国内中小学AI课程指南确定“达到某一发展水平的人应该能够做什么”。UNESCO的12个能力块和Understand—Apply—Create三级进阶特别适合形成纵向能力描述；华东师大—上海AI实验室的中小学AI课程指南已经把核心素养、课程目标、课程内容与学业质量评价连接起来。[53]

在**认知发展层**，研究不同年龄和角色对AI概念、伦理、人机协同和创造任务的掌握序列，形成AI素养learning progression。这里真正可产生教育学理论贡献的地方是发现：哪些能力存在先后依赖关系，哪些可以并行发展，AI工具使用经验是否改变这一发展序列。

在**测评理论层**，使用IRT回答“总体水平是多少”，使用CDM回答“哪些具体能力掌握了”，使用CAT/CD-CAT回答“怎样用更少题目得到同等精度”，使用跨群体测量不变性和DIF分析回答“不同性别、地区、年龄和学科的人拿到同样分数是否代表同样能力”。PISA已经长期使用IRT体系，并在阅读、数学、科学测评中逐步实施自适应测试。 54

在**学习分析层**，把静态作答升级为过程证据；在**大模型层**，解决开放任务评分、动态题目生成和语言反馈；最终所有算法仍需回到教育构念效度进行检验。ETS关于Responsible AI for Measurement and Learning的研究同样将公平、有效和测量目的放在AI模型选择之前。 55

推荐的核心研究内容

建议国家自然科学基金面上项目设置四个相互递进的研究任务。

研究任务A：AI素养跨群体动态构念与共尺度理论。

建立全民共同核心构念，开发K-12、大学生、教师、成人等角色模块；通过专家研究、认知访谈和多群组模型验证结构；研究AI技术快速变化下的measurement drift；识别稳定能力与技术特定能力。

预期算法包括多维IRT、层级潜变量模型、多群组测量不变性、DIF和纵向IRT。

研究任务B：人—AI交互过程证据驱动的认知诊断。

开发真实性任务，在受控大模型环境中获取prompt—response—revision全过程；研究“提问策略—核验行为—采纳策略—最终结果”与潜在能力状态之间的关系；建立过程序列到认知属性的可解释映射。

算法可比较序列Transformer、时序图模型、Hidden Markov/knowledge tracing、可解释状态空间模型，并与传统“仅答案”模型做增量效度比较。江波团队已公开研究知识追踪、时间模糊认知图和编程轨迹分析，为此类技术路线提供了国内可参照研究基础。 15

研究任务C：心理测量约束的可信LLM自动评分与自适应测验。

建立专家金标准开放题数据；比较多个模型、prompt和rubric方案；研究评分校准、不确定度估计、模型拒答、人机仲裁以及不同群体公平性；将开放题评分证据纳入MIRT/CDM；进一步以CD-CAT选择下一任务，并控制题目暴露率。

CAT能够根据早期表现调整后续题目难度，PISA已经在国际大规模测评中采用；CD-CAT则进一步将自适应能力估计与认知属性诊断结合。 56

研究任务D：诊断驱动的个性化指导及其作用机制。

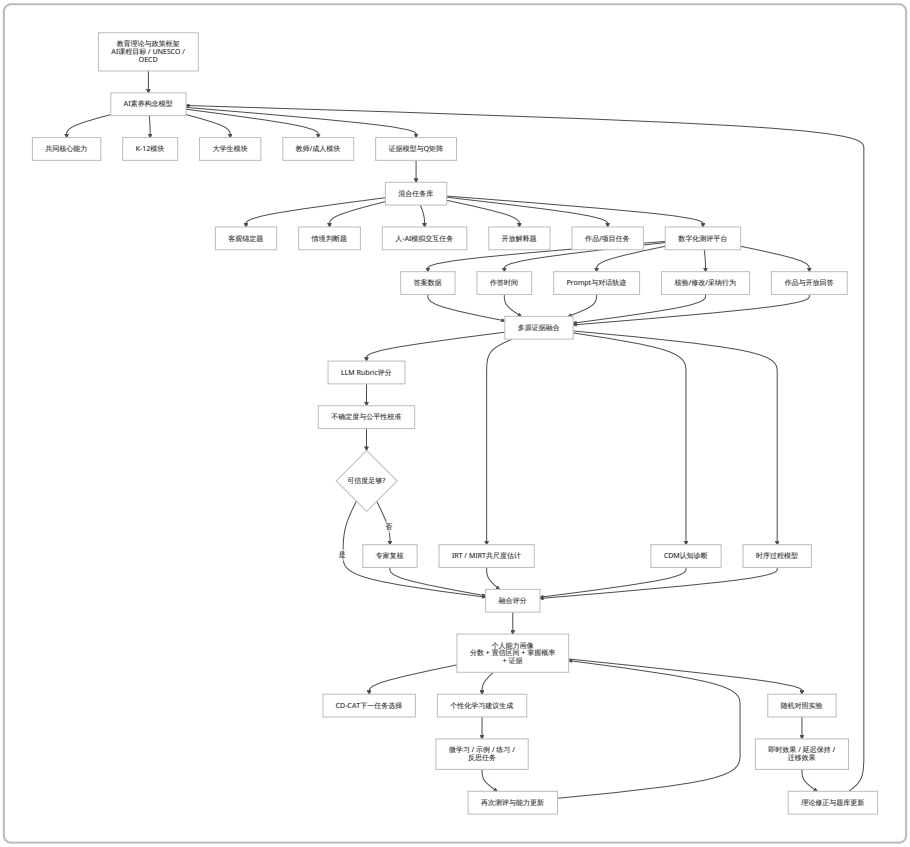
将诊断状态映射到微学习内容、示例、反例和下一任务；由LLM负责语言表达和情境适配，由规则/知识图谱/诊断模型限定允许推荐的知识点；通过随机实验比较一般反馈和诊断反馈，研究反馈对即时学习、延迟保持和迁移的作用机制。

由此形成真正的：

$$\boxed{\text{测 Measure} \rightarrow \text{诊 Diagnose} \rightarrow \text{导 Guide} \rightarrow \text{再测 Reassess}}$$

闭环。

总体技术路线图



这一技术路线中，**LLM只是G—H4以及M阶段的重要组件，并不控制整个测评体系。** 测评的构念来自教育理论，分数由心理测量框架约束，个性化指导通过实验验证；这种组织方式比“LLM直接出题—评分—推荐”的工程系统更符合教育信息科学基础研究逻辑。国际数字测评对过程数据、自适应测验和复杂任务的重视，以及ETS对AI评分效度和公平的研究，均支持这种分层设计。 57

算法研究可形成的创新点

建议把算法贡献集中在四个点，避免一份申请书罗列十几种模型。

动态多群体测量模型。 研究$\theta_{person,time,context}$而非静态$\theta$，显式分离“人的能力变化”“AI工具能力变化”和“题目难度变化”。这是AI素养相对于传统数学、阅读能力测量最值得研究的新问题之一。

过程增强认知诊断模型。 将答案、行为序列、prompt质量和核验路径转化为多源证据，研究过程证据是否提高认知属性分类准确率和解释性。当前CDM公平研究已指出，不同敏感属性群体可能产生诊断差异，因此公平约束应直接进入模型训练和验证。 58

校准型LLM评分。 预测“分数 + 评分不确定度 + 证据”，并设计“模型何时应放弃评分”的abstention机制。ETS及近期LLM评分研究已经把公平、解释性、人与机器一致性和评分可靠性视为核心问题。 59

诊断约束的个性化指导。 LLM不能自由决定学生学什么，而由认知诊断结果限定候选学习目标，再根据学习者语言水平和情境生成解释。这一“先诊断、后生成”的机制具有较强可解释性。

样本与实验设计

“全民”若理解为真正意义上的全国代表性人口调查，将明显超出普通面上项目的现实资源。因此建议在申请书中定义为：

> **建立可面向全民扩展的统一测量理论与平台架构，在代表性多群体样本上验证其跨群体可迁移性。**

而不要承诺“完成全国全民AI素养普查”。

对于NSFC面上项目，建议的研究样本为本报告的**规划估算**：

阶段	建议样本	核心目的
专家构念研究	20–30名	Delphi、Q矩阵、任务规范
认知访谈	40–80名	检查题意和思维过程
第一轮预测试	300–500名	题项筛选、初步因子结构
题库校准	2,000–3,000名	IRT/CDM参数和DIF
多地区主研究	6,000–10,000名	跨地区/跨群体外部验证
纵向子样本	800–1,200名	3次以上重复测量
个性化反馈RCT	600–1,200名	一般反馈 vs 个性化反馈
专家金标准开放作答	2,000–5,000份回答	LLM自动评分验证

地区可考虑上海 + 东中西部若干省份，覆盖城市/非城市、不同办学层次；具体合作地区**未指定**。ICILS等国际大规模数字测评采用跨地区抽样与数字任务的经验说明，测评平台、抽样设计和量尺等值应该从研究初期同步考虑。 [60]

建议将最终验证拆成五类证据：

结构效度：CFA/ESEM、IRT/CDM拟合、Q矩阵验证。

收敛/区分效度：与AI知识测试、自陈AI素养、计算思维等相关但不同构念比较。

效标效度：预测真实AI任务表现；GLAT研究正采用了类似“测验分数能否预测GenAI支持任务表现”的思路。 [61]

公平性：性别、城乡、区域、年龄、学科、技术经验、特殊需要群体的DIF和测量不变性；AI评分还增加模型差异预测偏差检查。 [62]

干预效度：接受个性化指导后是否在未见过的新型AI任务中产生迁移，而非只提高类似题成绩。

计算平台与工程资源

不建议为本项目训练一个基础大模型。科研经费更值得用于**测量数据、专家标注和受控推理实验**。拟议研究可以比较商业闭源模型与开源7B—70B级模型，但只需对较小模型进行LoRA/adapter层面的实验；开放题自动评分尤其需要跨模型复现，防止研究结论绑定某一个API版本。

建议工程架构由七个服务组成：

> **测评前端 → 安全题库服务 → 事件日志服务 → 心理测量服务 → LLM评分网关 → 个性化反馈服务 → 脱敏研究数据库**

LLM网关记录模型名称、版本、prompt模板、temperature等参数，以支持实验复现。长期测评必须记录模型版本，因为同一任务在模型升级后可能变得更容易，这正是AI素养测量中的“环境漂移”。

推荐最低科研资源为：一套GPU服务器或校级算力账户、受控大模型API额度、关系数据库与对象存储、日志分析环境以及2—5TB加密研究存储空间。**现有校内GPU/云资源：未指定。** 在经费有限的上海自然科学基金版本中，优先购买云端/校内算力时长，而非采购大型GPU服务器，更有利于把资金投向数据质量。

申报题目、研究目标、里程碑与预算

最推荐的项目题目

综合F0701风格、科学问题集中度和课题组方向，本报告优先推荐以下题目。

优先级A：最完整、最适合NSFC面上

中文：

> **面向多群体的人工智能素养动态测量与自适应认知诊断机制研究**

英文：

> **Dynamic Measurement and Adaptive Cognitive Diagnosis of Artificial Intelligence Literacy across Diverse Populations**

该题目的优势是将“全民”转换成“多群体”，将“体系建设”转换成“动态测量和诊断机制”，既包含AI素养，又有明确自然科学问题。

核心目标：

1. 揭示多年龄、多角色群体AI素养共同与特异潜在结构及其动态演化规律；
2. 建立融合结果数据与人—AI交互过程数据的AI素养认知诊断模型；
3. 构建跨群体共尺度的自适应测验机制；
4. 验证诊断驱动个性化指导对AI素养发展和迁移的作用机制。

优先级A：更突出大模型特色

中文：

> **基于人—大模型交互过程证据的人工智能素养测量与可解释诊断研究**

英文：

> **Measuring and Explainably Diagnosing AI Literacy through Human–Large Language Model Interaction Process Evidence**

这个题目尤其适合突出原创点：传统AI素养研究测“你觉得自己会不会AI”，拟议研究测“你实际上如何和AI共同完成任务”。

核心目标是建立人—LLM交互过程证据理论、过程增强潜变量模型、可解释认知诊断和跨任务效度验证。

优先级A：最适合大模型自动评分

中文：

> **心理测量约束的大模型开放式智能测评与人工智能素养自适应诊断研究**

英文：

> **Psychometrically Constrained Large-Language-Model Scoring and Adaptive Diagnosis of AI Literacy**

这一版本算法浓度最高。可以把LLM评分误差、不确定度、人机评分仲裁、IRT/CDM联合估计作为主要原创问题。ETS和当前LLM自动评分研究对可信、解释、公平评分的持续关注说明这个问题具有较好的国际前沿性。 63

优先级B：适合上海自然科学基金

中文：

> **中小学生人工智能素养情境化自动测评与过程诊断方法研究**

英文：

> **Contextualized Automated Assessment and Process-Based Diagnosis of AI Literacy for K–12 Students**

与江波承担的“中小学信息科技核心素养自动评价研究”形成明显的学术延伸，但对象转向AI素养、证据转向人—AI交互，可清楚说明已有项目与本项目的差异。 15

优先级B：突出公平和全民尺度

中文：

> **人工智能素养跨群体共尺度测量与公平自适应评估机制研究**

英文：

> **Cross-Population Common-Scale Measurement and Fair Adaptive Assessment of AI Literacy**

这一题目的优势是理论性强，能够解决“全民”测评的真正难点：不同人群是否可以比较、比较是否公平。

优先级B：突出测—诊—导闭环

中文：

> **人工智能素养“测—诊—导”一体化动态评估与个性化发展机制研究**

英文：

> **An Integrated Measure–Diagnose–Guide Framework for Dynamic AI Literacy Assessment and Personalized Development**

这一题目应用价值很强，但申请书中应注意把“平台建设”放在验证层，把“动态评估与个性化发展机制”放在科学问题层。

一套可直接转入申请书的总目标

建议总体目标写成：

> 面向人工智能技术快速演化和学习者群体高度异质条件下传统AI素养静态、自陈测量难以真实表征能力的问题，以学习目标与认知发展理论为基础，研究AI素养跨群体潜在结构及其动态演化规律；构建融合客观作答、人—大模型交互过程和开放作品的多源证据模型，研究心理测量约束的大模型可信评分与自适应认知诊断机制；揭示诊断反馈促进AI素养发展及能力迁移的作用规律，从而形成可面向不同年龄与角色群体扩展的AI素养智能测评理论与方法体系。

相应的四个研究目标建议控制在“理论—模型—算法—实证”四层，避免出现十几个平行目标。

预期理论贡献

第一，提出**“人机协同情境中的AI素养”动态构念理论**，将AI能力从静态知识、态度、自我效能扩展为“识别—交互—评价—协同—责任”的可观察表现。UNESCO和OECD最新框架均强化了人类主体性、伦理、使用、创造与塑造AI，这为构念升级提供了国际理论基础。[7]

第二，建立**跨群体AI素养共同量尺与角色模块理论**，解释哪些能力可以全民比较、哪些能力需要年龄/职业特定测量。

第三，建立**过程证据—潜在能力映射理论**，回答AI素养在真实人机交互中如何被观察和推断。

第四，形成**心理测量约束的大模型智能评价理论**，将LLM看作存在测量误差和不确定性的“评分者”，而非绝对评分标准。

第五，通过RCT检验，形成**“诊断精度—反馈类型—学习增长—迁移表现”机制模型**，使评价研究最终回到教育效果。

建议里程碑

对于四年NSFC面上项目，可设计为：

时间	核心工作	关键交付
第一年	构念、learning progression、证据模型、伦理审批；专家研究与认知访谈	AI素养理论框架；首批400+候选题/任务；预测试数据

时间	核心工作	关键交付
第二年	题库校准、多群组IRT/CDM；交互任务平台；过程数据建模	公共量尺；Q矩阵；过程增强诊断模型；首版数据集
第三年	LLM可信评分、CD-CAT、自适应任务；多地区大样本	自适应测评原型；评分基准；多地区外部验证
第四年	个性化反馈RCT、纵向模型、漂移研究、理论整合	测—诊—导闭环验证；开放规范/脱敏benchmark；理论模型

对于三年上海项目，建议将主题缩减为：

> **第一年构念+题库；第二年过程诊断+自动评分；第三年系统验证+反馈实验。**

不要在20—25万元级别项目里同时承诺全国样本、几十亿参数模型训练、APP、知识图谱、大规模RCT和完整行业标准。

粗略预算建议

以下属于**科研工作量估算，不是基金委规定额度**。国家自然科学基金面上项目2025年平均直接费用约50万元，可先以约50万元作为内部方案设计基线；最终仍需按照申请年度预算政策编制。 17

NSFC面上内部测算：约50万元

工作包	粗估	主要用途
多地区样本与测评实施	8万元	学校协调、被试组织、测评实施
专家标注与研究劳务	8万元	rubric、Q矩阵、双重评分、数据整理
LLM API/GPU/云计算	8万元	多模型评分、推理、模型比较实验
平台开发与安全测试	7万元	交互任务、日志系统、部署
纵向与RCT实验	6万元	重复测量、反馈实验
合作交流与调研	4万元	多地区协同、研究访问
数据治理与存储	3万元	加密存储、备份、脱敏
学术交流/成果传播等	6万元	论文、会议、数据和工具整理
合计	**约50万元**	内部粗估

对于上海项目，2025年度面上项目是定额20万元、青年项目25万元；下一轮金额尚应以新指南为准。 64

若按20万元PoC版本设计，建议约5万元投入样本采集与实验、4万元投入算力/API、3万元投入专家标注、3万元投入平台、3万元投入研究劳务、2万元投入协同和成果整理。大规模外省样本、GPU设备购置和复杂多模态生理采集都可以暂缓。

一个较现实的申报组合

如果课题组计划连续布局，可以形成：

上海自然科学基金：核心算法与上海样本验证

↓

NSFC F0701面上：跨群体共尺度 + 过程证据 + 自适应诊断

↓

教育部/重点研发/行业合作：全民平台工程化与大规模应用

这一顺序与江波团队公开项目路径有相似之处：从图形化编程自动评价、信息科技核心素养自动评价逐步进入自适应学习、对话导学和教育大模型研究。 15

优先来源与检索策略

最值得优先精读的来源

第一梯队：基金与政策原始来源。 申报前应以国家自然科学基金委当年度《项目指南》、F信息科学部申请代码、申请规定和科学部资助注意事项为唯一最终依据；上海项目则以上海市科委当年度自然科学基金申报指南和《上海市自然科学基金管理办法》为准。当前2026年F0701代码及上海2025规则均已由本报告核实。 65

第二梯队：国内同赛道课题组。 华东师范大学江波团队应作为重点跟踪对象，其公开项目连续覆盖编程项目自动评价、中小学信息科技核心素养自动评价、知识追踪、自适应学习、教育大模型与对话生成；华中师范大学孙建文团队正在开展“数智驱动的青少年人工智能素养测评”；北京大学尚俊杰的F0701“视频游戏空间能力测评”则是测评技术类NSFC直接案例。 66

第三梯队：国内AI素养测评工具。 优先精读武汉大学AILES-CS、刘明等GenAI素养测评，以及2026年“基于69项研究的AI素养测评系统回顾”。其中AILES-CS特别适合作为你们未来研究中的**传统自陈测量baseline**，而不是终点。 67

第四梯队：国际构念框架。 UNESCO 2024学生/教师AI能力框架和OECD/European Commission 2026 AI Literacy Framework，应成为申报书国际理论背景的两根主轴；Long & Magerko 2020用于解释AI literacy学术源流。 68

第五梯队：国际真实任务测评。 PISA 2029 MAIL、PISA数字化过程数据、ICILS、Bebras和Dr. Scratch最值得用于题型和技术路线设计。这些案例共同支持从“问卷”升级到数字情境、作品、互动和过程数据。 69

第六梯队：心理测量与LLM评分。 GLAT、AICOS作为AI素养客观测验前沿；CD-CAT文献作为自适应诊断基础；ETS和ACL的LLM自动评分工作作为开放题可信评价基础。 70

建议的数据库与检索顺序

中文检索建议按照“**官网 → CNKI/万方 → 高校主页 → 期刊官网 → 学者主页**”顺序执行。核心关键词可组合为：

`人工智能素养 + 测评 / 评价 / 评估 / 量表 / 核心素养 / 学业质量`

`生成式人工智能素养 + 测评 / 客观测验 / 情境任务`

`人工智能素养 + 认知诊断 / 项目反应理论 / 自适应测验`

`计算思维 + 自动评价 / Scratch / 编程轨迹 / 认知诊断`

`智能评价 + F0701 / 教育信息科学与技术`

`江波 + 自动评价 / 核心素养 / 图形化编程 / 自适应学习`

`孙建文 + 人工智能素养测评 / 教学诊断`

`大语言模型 + 自动评分 / 智能测评 / 开放题 / 教育评价`

当前中文系统回顾已纳入69项AI素养测评研究，因此可以把其参考文献表作为中文和国际量表的“种子文献池”，再沿引用关系向前后扩展。 [71]

英文建议采用：

`"AI literacy" AND assessment`

`"artificial intelligence literacy" AND objective measurement`

`"generative AI literacy" AND test`

`"AI literacy" AND "item response theory"`

`"AI literacy" AND performance-based assessment`

`"human-AI interaction" AND assessment AND process data`

`"large language model" AND automated scoring AND education`

`cognitive diagnosis AND computerized adaptive testing`

`AI literacy AND measurement invariance`

`AI literacy AND differential item functioning`

优先数据库为Web of Science、Scopus、ERIC、ACM Digital Library、IEEE Xplore、Springer、ScienceDirect和ACL Anthology；技术性结论应回到原始论文，框架性结论优先使用UNESCO、OECD、IEA、ETS等机构原始文件。

后续文献筛选应建立的编码表

为了最终转化成基金申请书，建议给每篇文献统一编码以下字段：

研究维度	编码内容
构念	AI素养定义、一级/二级维度

研究维度	编码内容
对象	年龄、年级、职业、地区
题型	Likert、MCQ、SJT、开放题、交互任务、作品
数据	答案、时间、日志、文本、代码、多模态
测量模型	CTT、CFA、IRT、MIRT、CDM、CAT
AI算法	NLP、LLM、序列模型、知识追踪等
标注	专家数量、双标、仲裁、人机标注
质量	信度、结构效度、效标效度、测量不变性
公平	DIF、群体偏差、可解释性
反馈	总分、能力画像、误概念、学习推荐
实验	横断、纵向、外部验证、RCT
工程	平台、题库、自适应引擎、数据治理
伦理	知情同意、未成年人、隐私、LLM数据出境/第三方
可借鉴点	对本项目可直接迁移的方法
局限	下一项研究可解决的问题

采用这个编码框架，文献综述最终就能自然导向基金申请中的“**现有研究做到什么—还缺什么—为什么现有方法解决不了—本项目提出什么新理论和算法**”，而不会停留在按作者逐篇罗列。

最终申报叙事建议

从现有文献和F0701项目轨迹综合判断，最有潜力的一条主线可以压缩成一句话：

> **现有AI素养测评主要解决“测什么”和“自我感觉如何”，本项目进一步解决“真实人机协同中能力如何表现、如何被可靠估计、如何跨人群比较、如何依据诊断促进能力发展”。** AILES-CS所代表的国内指标—量表研究、GLAT/AICOS所代表的国际客观测量，以及PISA 2029 MAIL所代表的交互式真实性测评，恰好构成了这一研究演进链。 72

这条路线也最容易把教育学、心理测量与计算实现真正整合：**教育学规定要发展的能力与进阶规律；测量理论规定从何种证据推断能力及其不确定性；人工智能负责从复杂过程数据和开放作答中提取证据；学习科学与实验设计负责证明个性化指导是否产生真实学习增长。**

从自然科学基金评审视角看，最终申请书最应突出四个词：**动态构念、过程证据、可信诊断、因果反馈。** 平台、题库、大模型、知识图谱、智能体都可以出现，但应作为回答这四类科学问题的研究工具，而非项目的最终科学贡献。国家自然科学基金和上海自然科学基金公开规则对关键科学问题、原创性、理论基础、科学价值和可行性的持续强调，也支持这一申报组织方式。 73

---

1 9 nsfc.gov.cn
https://www.nsfc.gov.cn/u/cms/www/202601/16170940a7sq.jpg

2 15 66 教育学部
https://faculty.ecnu.edu.cn/_s8/jb2/main.psp

3 12 73 自然科学基金委化学科学部召开2026年度重点项目评审会议
https://www.nsfc.gov.cn/p1/3381/2821/139060.html?utm_source=chatgpt.com

4 26 Empowering Learners for the Age of AI
https://www.oecd.org/en/publications/empowering-learners-for-the-age-of-ai_65cd27d4-en.html?utm_source=chatgpt.com

5 20 34 67 72 Construction of AI Literacy Evaluation System for College Students and an Empirical Study at Wuhan University
https://journal.hep.com.cn/fde/EN/10.1007/s44366-025-0039-x

6 33 36 43 46 59 63 Examining the responsible use of zero-shot AI approaches ...
https://www.fr.ets.org/research/archive/examining-the-responsible-use-of-zero-shot-ai-approaches-to-scor.html?utm_source=chatgpt.com

7 38 41 53 391105eng.pdf
https://unesdoc.unesco.org/in/documentViewer.xhtml?ark=%2Fark%3A%2F48223%2Fpf0000391105%2FPDF%2F391105eng.pdf.multi&file=%2Fin%2Frest%2FannotationSVC%2FDownloadWatermarkedAtt
f4c3b0f2b5c3%3F_%3D391105eng.pdf&fullScreen=true&id=p%3A%3Ausmarcdef_0000391105&locale=en&updateUrl=updateUrl8037&v=2.1.196&utm

8 17 面上项目
https://www.nsfc.gov.cn/p1/2791/2809/120767.html?utm_source=chatgpt.com

10 19 尚俊杰
https://www.gse.pku.edu.cn/szdw/jxkyry/jyjzx/1051jyxy32248.htm?utm_source=chatgpt.com

11 孙建文
https://xai.ccnu.edu.cn/jwsun/?utm_source=chatgpt.com

13 信息公开目录
https://kjgl.stcsm.sh.gov.cn/wdcms/kjzc/32.jhtml

14 Innovating Assessments to Measure and Support Complex ...
https://www.oecd.org/en/publications/innovating-assessments-to-measure-and-support-complex-skills_e5f3e341-en/full-report/component-19.html?utm_source=chatgpt.com

16 64 上海市科学技术委员会关于发布2025年度基础研究计划“自然 ...
https://stcsm.sh.gov.cn/zwgk/kyjhxm/xmsb/20250126/86f5c86419764eaabca96179149fd742.html?utm_source=chatgpt.com

18 2023年国家级、省部级在研项目一览 - 上海数字化教育装备工程技术 ...
https://ercdee.ecnu.edu.cn/4a/a0/c16574a740000/page.htm?utm_source=chatgpt.com

21 71 AI素养测评的研究图景——基于69项研究的系统回顾
https://www.kmf.ac.cn/CN/10.13266/j.issn.2095-5472.2026.005?utm_source=chatgpt.com

22 中小学人工智能课程指南
https://xbjk.ecnu.edu.cn/CN/10.16382/j.cnki.1000-5560.2023.03.013?utm_source=chatgpt.com

23 “智慧教育示范区”创建项目
https://cit.bnu.edu.cn/ai4edu/zjgd/92385.html

24 37 What is AI Literacy? Competencies and Design ...
https://dl.acm.org/doi/10.1145/3313831.3376727?utm_source=chatgpt.com

25 68 AI competency framework for students | UNESCO
https://www.unesco.org/en/articles/ai-competency-framework-students?hub=343&utm_source=chatgpt.com

27 69 PISA: Programme for International Student Assessment
https://www.oecd.org/en/about/programmes/pisa.html?utm_source=chatgpt.com

28 GLAT: The generative AI literacy assessment test
https://www.sciencedirect.com/science/article/pii/S2666920X25000761?utm_source=chatgpt.com

29 40 70 Objective measurement of AI literacy: Development and ...
https://www.sciencedirect.com/science/article/pii/S2666920X25001250?utm_source=chatgpt.com

30 Bebras
https://www.bebras.org/?utm_source=chatgpt.com

31 44 Dr. Scratch
https://www.drscratch.org/?utm_source=chatgpt.com

32 60 ICILS 2023
https://www.iea.nl/studies/iea/icils/2023?utm_source=chatgpt.com

35 54 56 PISA Frequently Asked Questions (FAQs)
https://www.oecd.org/en/about/programmes/pisa/pisa-frequently-asked-questions-faqs.html?utm_source=chatgpt.com

39 AI competency framework for teachers
https://www.unesco.org/en/articles/ai-competency-framework-teachers?utm_source=chatgpt.com

42 PISA 2029 Media and Artificial Intelligence Literacy | OECD
https://www.oecd.org/en/about/projects/pisa-2029-media-and-artificial-intelligence-literacy.html

45 Novel item selection strategies for cognitive diagnostic ...
https://link.springer.com/article/10.3758/s13428-023-02228-9?utm_source=chatgpt.com

47 Combining computer adaptive testing technology with ...
https://link.springer.com/article/10.3758/BRM.40.3.808?utm_source=chatgpt.com

48 关于印发《科技伦理审查办法（试行）》的通知
https://www.most.gov.cn/xxgk/xinxifenlei/fdzdgknr/fgzc/gfxwj/gfxwj2023/202310/t20231008_188309.html?utm_source=chatgpt.com

49 个人信息保护法：为数字社会治理与数字经济发展构建基本法
https://www.cac.gov.cn/2021-08/25/c_1631491548474109.htm?utm_source=chatgpt.com

50 专家解读｜坚持创新引领促进生成式人工智能健康发展
https://www.cac.gov.cn/2023-08/29/c_1694965943877940.htm?utm_source=chatgpt.com

51 中华人民共和国个人信息保护法
https://www.cac.gov.cn/2021-08/20/c_1631050028355286.htm?utm_source=chatgpt.com

52 国家互联网信息办公室有关负责人就《生成式人工智能服务 ...
https://www.cac.gov.cn/2023-07/13/c_1690898326863363.htm?utm_source=chatgpt.com

55 Responsible AI for Measurement and Learning - ERIC
https://rr.ets.org/index.php/etsrr/article/download/9/5/10?utm_source=chatgpt.com

57 Digital assessment: OECD Digital Education Outlook 2023
https://www.oecd.org/en/publications/oecd-digital-education-outlook-2023_c74f03de-en/full-report/digital-assessment_a102e604.html?utm_source=chatgpt.com

58 Understanding and improving fairness in cognitive diagnosis
https://link.springer.com/article/10.1007/s11432-022-3852-0?utm_source=chatgpt.com

61 GLAT: The generative AI literacy assessment test
https://research.monash.edu/en/publications/glat-the-generative-ai-literacy-assessment-test/?utm_source=chatgpt.com

62 Identifying Features Contributing to Differential Prediction ...
https://www.pt.ets.org/research/archive/identifying-features-contributing-to-differential-prediction-bia.html?utm_source=chatgpt.com

65 信息科学三处
https://www.nsfc.gov.cn/p1/2931/3971/3975/3989/4035/xxkxsc222.html?utm_source=chatgpt.com